

Лабораторная работа №12

XML документы

Цель: познакомиться с языком разметки данных XML, изучить правила построения HTML документов

Теоретические сведения

Устройство XML документа

Синтаксически в XML, по сравнению с HTML, нет ничего нового. Это такой же текст, размеченный тэгами, но с той лишь разницей, что в HTML существует ограниченный набор тэгов, которые можно использовать в документах, в то время, как XML позволяет создавать и использовать любую разметку, которая может понадобиться для разметки данных.

Несомненным достоинством XML является и то, что это достаточно простой язык. Основных конструкций в XML мало, но, несмотря на это, с их помощью можно создавать разметку документов практически любой сложности.

Для демонстрации структуры XML документа лучше обратиться к какому нибуть примеру. Рассмотрим следующий XML документ:

```
<?xml version="1.0" ?>
<корневой_элемент>
  <элемент>
    Текст <еще_элемент атрибут="значение" /> текст ...
  </элемент>
  Текст текст текст <элемент>текст текст... </элемент> ...
</корневой_элемент>
```

Рассмотрим данный пример подробно. Первая строка документа определяет его как XML документ, построенный в соответствии с первой версией языка (**version="1.0"**). В этой же конструкции можно указать и кодировку, в которой создан документ:

```
xml version="1.0" encoding="Windows-1251" ?>.
```

Кодировкой по умолчанию для XML является **unicode**. Далее находится открывающий тэг корневого (главного) элемента **<корневой_элемент>**, содержащий элемент **<элемент>**, который, в свою очередь, содержит элемент **<еще_элемент атрибут="значение" />** с атрибутом **атрибут**. Как видно из примера, правила записи элементов, атрибутов и их значений в XML ничем не отличаются от правил записи элементов атрибутов и их значений в HTML (также есть открывающие и закрывающие тэги элементов, элементы с содержимым и без и т.д.), только набор элементов несколько расширен, благодаря чему мы и можем "нагрузить" разметку семантикой.

Ниже приводятся несколько правил построения XML документа. Итак:

- любой XML документ должен начинаться строкой **<?xml version="1.0" ?>**
- любой XML документ должен иметь единственный (не более, не менее!) корневой элемент; например, в HTML для этих целей использовался элемент **<html>**, в примере выше - это **<корневой_элемент>**.
- кодировкой по умолчанию для символов XML документа является **Unicode** кодировка **UTF-8**, поэтому XML файлы должны быть сохранены в соответствующей кодировке или в 1-й строке документа должна быть задана кодировка

документа, например **encoding**="Windows-1251" (при работе только с латиницей это никак себя не проявляет, так как кодировка этих символов в **ASCII** совпадает с **UTF-8**).

- правила записи большинства конструкций языка совпадает с правилами **XHTML**, изучавшемся вами ранее (более подробно речь об основных конструкциях языка пойдет далее в уроке).

XML документ представляет собой обыкновенный текстовый файл с расширением **.xml**. Единственная особенность их заключается в том, что для символов файла рекомендуется использовать кодировку **Unicode**.

Основные конструкции XML

Помимо элементов, атрибутов и текста, документы могут содержать и другие конструкции, такие как комментарии, инструкции по обработке и секции символьных данных. Эти базовые составляющие используются для того, чтобы гибко, но в четком соответствии со стандартами, размечать документы любой сложности. Рассмотрим эти конструкции поподробнее.

Элемент

Тэги в XML документе не просто размечают текст - они выделяют объект, называемый *элементом*. Элементы являются основными структурными единицами XML - именно они иерархически организуют информацию, содержащуюся в документе. Элементы могут быть пустыми, т.е. не содержать ни данных, ни других конструкций, или непустыми - включать в себя текст, другие элементы и т. п.

Пустой элемент имеет следующий вид:

```
<элемент атрибут="значение" атрибут="значение" ... />
```

Примерами таких элементов в знакомом HTML являются: **
, ** и др.

Непустые элементы имеют вид:

```
<элемент атрибут="значение" атрибут="значение" ...> ... Содержимое  
элемента ... </элемент>
```

В HTML таких элементов большинство: **<body> ... </body>**, **<p> ... </p>** - в этих элементах может располагаться как текст, так и другие элементы (таблицы, рисунки...).


Необходимо помнить об одной **очень** важной особенности XML: имена в XML - регистро-зависимы, то есть **<Sample-element />**, **<SAMPLE-ELEMENT />** и **<sample-element />** - совершенно разные элементы.

Легко заметить, что документ, состоящий из вложенных друг в друга элементов, подобен дереву: родительский элемент является **корнем**, дочерние элементы - **ветками**, а если они не содержат ничего более - **листьями**:

```
<library>  
  <book>  
    <title value="Технология XSLT" />  
    <author fio="Алексей Валиков" />  
    <publisher>  
      <name value="BHV" />  
      <homepage url="http://www.bhv.com" />  
    </publisher>  
  </book>  
  ...
```

</library>

Графически этот пример выглядит следующим образом:



В данном случае <library> является корнем, <book> и </publisher> - ветви, а <title>, <author>, <name> и <homepage> - листья

Внимание: в XML требуется тщательно следить за правильностью вложения элементов друг в друга - элементы, раньше открытые, должны быть позже закрыты. В противном случае не может быть и речи о иерархической структуре документа.

<A>

а) пример неправильного вложения элементов

<A>

б) пример правильного вложения элементов

Атрибут

В элементах можно использовать *атрибуты* с присвоенными им значениями. Атрибут задается следующим образом:

атрибут = "значение"

В отличие от HTML в XML атрибуты всегда должны иметь **значение!** Значение атрибута заключается в двойные или одинарные кавычки. При необходимости, можно использовать одинарные кавычки внутри двойных и наоборот.

<company name = 'Акционерное Общество "Витязь" ... /> ... <book author = "О'Генри" ... />

Имена в XML регистро-зависимые. Это относится не только к элементам, но и к атрибутам.

Символьные данные: секция CDATA

Секция *CDATA* выделяет часть документа, внутри которых текст не должен восприниматься как разметка. CDATA означает буквально "character data" - символьные данные. Вот пример секции CDATA:

<![CDATA[содержимое]]>

Внутри секции **CDATA** могут располагаться любые символы, даже < и & - они не будут восприниматься анализатором как управляющие. Единственная последовательность, которая не должна присутствовать в **CDATA**, это "]]>" - окончание символьных данных.

Комментарии

XML документ может содержать комментарии, записываемые следующим образом:

<!-- Это комментарий --> ... <!-- комментарии могут охватывать несколько строк -

->

Текст комментария может состоять из любых символов, кроме двух "-" подряд ("--").

Задание на лабораторную работу

Создать XML документ, содержащий информацию о какой-либо предметной области. Название предметной области согласовать с преподавателем. Для оформления XML документа использовать знания и пользоваться правилами, указанными в теоретических сведениях. Проверить документ на действительность.

The Apache Software Foundation создала набор ПО, представляющего собой парсеры и другое обеспечение для работы с XML. Одним из таких известных парсеров является Xerces. Он существует в виде отдельного ПО, реализованного на C++ или Java. Чтобы не ограничивать Вас в выборе инструментальной среды и ОС, будем использовать Java реализацию ввиду ее кроссплатформенности и простоты использования.

Замечание. Для запуска Java приложения необходимо, чтобы на компьютере была установлена Java машина от Sun. Желательно с Java SDK.

Проверить действительность My.XML можно командой
`java sax.counter my.xml`

При необходимости нужно явно указать путь к архивам Xerces ключом **-classpath**
`java -classpath "PATH\XercesImpl.jar;PATH\XercesSamples.jar" sax.Counter my.xml`
(замените **ПАТН** на свой путь к местоположению архивов)
Сам Xerces с официального сайта.

Требование к отчету:

- титульный лист, номер и название лабораторной работы;
- цель работы, задание на работу;
- листинг программы (файла);
- скриншот результатов работы программы;
- выводы по работе;
- ответы на контрольные вопросы (при наличии).